

智慧登山杖
結合 IMU 與 AI 疲勞監測的登山安全輔助系統

專題參與人員：

組別：第4組

班別： 四慧三乙 座號： 30 姓名： 黃大恩
班別： 四慧三乙 座號： 24 姓名： 趙右詮
班別： 四慧三乙 座號： 11 姓名： 張祐霖

指導老師：劉秉睿

中華民國 年 月 日

目錄

一、 前言	1
(一) 動機	1
(二) 文獻回顧	2
二、 專題簡介	3
(一) 疲勞預警系統	3
(二) SDR 緊急通訊救援系統	3
(三) 行動端應用程式 (APP)	4
三、 製作理論探討	4
(一) 疲勞預警系統	4
(二) SDR 緊急通訊救援系統(對講機音訊辨識模型)	16
(三) SDR 緊急通訊救援系統(手機訊號辨識)	19
(四) 行動端應用程式 (APP)	24
四、 軟硬體分析	28
(一) 軟體	28
(二) 硬體	28
五、 測試結果	30
(一) 疲勞預警系統	30
(二) SDR 緊急通訊救援系統(對講機音訊辨識模型)	33
(三) SDR 緊急通訊救援系統(手機訊號辨識)	35
六、 結論	37
七、 建議	37
(一) 擴充真實步態資料庫與提升模型泛化能力	38
(二) 硬體功耗管理與系統續航力最佳化	38
(三) 多模態生理數據之融合潛力	38
(四) 感測器物理姿態自適應校正機制	38
八、 參考文獻	38

圖目錄

圖 1.疲勞辨識系統整體流程圖.....	4
圖 2. 三汀山數據採集路線.....	4
圖 3. 大坑數據採集路線.....	4
圖 4. 登山杖嵌入式感測模組原型.....	7
圖 5. 感測器方向.....	7
圖 6. 數據蒐集流程.....	7
圖 7. 正常狀態.....	7
圖 8. 疲勞狀態.....	7
圖 9. 原始波形(加速度).....	10
圖 10. 原始波形(陀螺儀).....	10
圖 11. $\sigma = 0.3$ (加速度).....	10
圖 12. $\sigma = 0.3$ (陀螺儀).....	10
圖 13. $\sigma = 2.0$ (加速度).....	10
圖 14. $\sigma = 2.0$ (陀螺儀).....	10
圖 15. Diffusion 模型架構	12
圖 16. Diffusion 模型 Training Loss 曲線圖	12
圖 17. 生成數據(加速度).....	12
圖 18. 生成數據(陀螺儀).....	12
圖 19. 模型架構示意圖.....	13
圖 20. 模型架構示意圖.....	15
圖 21. 模型架構示意圖.....	16
圖 22. 數據採集地點(三汀山).....	16
圖 23. 軟體定義無線電模組.....	16
圖 24. 訓練集正樣本示意圖.....	17
圖 25. 訓練集負樣本示意圖.....	17
圖 26. 收集設備架構 RTL-SDR 連接電腦	20
圖 27. 管理館地下室 B1	20
圖 28. 工程館地下室 B1	20
圖 29. 整體處理流程圖.....	21
圖 30.首頁：疲勞監測.....	26
圖 31. 離線地圖.....	26
圖 32.天氣預報介面.....	26
圖 33.SDR 緊急求救系統.....	26
圖 34. JupyterLab.....	29
圖 35. Android Studio	29
圖 36.Anytalk FT-388GPS.....	29
圖 37.手機.....	29
圖 38. 模型訓練之損失曲線.....	31
圖 39. A 同學自適應機制消融實驗	31
圖 40. A、B 同學校正前後比較	32
圖 41. A 同學 LDA 結果圖	32
圖 42. B 同學 LDA 結果圖.....	32
圖 43. 接收端植物分佈.....	34

圖 44. 訓練之損失與準確率曲線圖.....	34
圖 45. 模型訓練曲線.....	36
圖 46. 模型最後偵測能力總結圖.....	36
圖 47. 不同距離下 <code>visible_signal</code> 最後準確率	36

表目錄

表 1.各類別資料增強策略總覽.....	10
表 2.參數配置.....	10
表 3. GRU 模型架構與訓練超參數配置表	13
表 4.收集項目與參數設定.....	20
表 5.前處理事項.....	21
表 6.特徵樣式.....	21
表 7.模型主要參數整理.....	23
表 8. 基準模型 K 折交叉驗證效能指標統計表.....	31
表 9. A 同學自適應機制消融實驗效能對比表	32
表 10. 各距離推論結果.....	34

智慧登山杖：結合 IMU 與 AI 疲勞監測的登山安全輔助系統

Smart Trekking Pole: A Hiking Safety Assistance System Integrating IMU and AI Fatigue Monitoring

張祐霖, 黃大恩, 趙右詮, 劉秉睿

You-Lin Zhang, Da-En Huang, You-Quan Zhao, Ping-Juei Liu

國立勤益科技大學人工智慧應用工程系

Department of Artificial Intelligence and Computer Engineering

National Chin-Yi University of Technology

摘要

本研究開發「結合 IMU 與 AI 疲勞監測之登山安全輔助系統」，透過將六軸慣性感測器整合至單一登山杖，並採集真實步態數據、導入擴散模型與自適應機制，結合 GRU 模型分析訊號，以達成零負擔且具泛化力的精準疲勞特徵辨識。同時，系統整合軟體定義無線電與 2D CNN 音訊辨識模型，自動偵測微弱求救訊號，以達成突破深山通訊盲區的主動求救。最終將功能整合至手機應用程式，達成兼具事前預警與災後救援的全面性登山安全防線。

Abstract

This research presents an AI-powered mountaineering safety and fatigue monitoring system, which integrates six-axis Inertial Measurement Units (IMU) into a single trekking pole. Leveraging real-world gait data, diffusion models, and domain adaptation mechanisms, the system utilizes Gated Recurrent Units (GRU) to achieve non-invasive and generalized precision in fatigue identification. Concurrently, the integration of Software-Defined Radio (SDR) and 2D Convolutional Neural Network (CNN) audio recognition models allows for the autonomous detection of faint distress signals, effectively overcoming communication blind spots in deep mountainous terrain. These functionalities are consolidated into a mobile application, establishing a comprehensive safety framework that provides both proactive fatigue alerts and resilient emergency rescue support.

一、前言

(一)動機

臺灣具備極高的山林密度，在全球地理環境中名列前茅。隨著國民健康意識的提升與戶外運動普及，登山已躍升為臺灣民眾最主要的體育與休閒活動之一。然而，隨著攀登人口基數的擴大，山域事故（山難）的發生頻率亦逐年居高不下，每年均造成顯著的人員傷亡與搜救資源的龐大支出。根據內政部消防署的統計資料顯示，民國 114 年度之山域事故救援案件數達 531 件，發生人數共計 727 人，其中獲救人數為 680 人（93.54%），而死亡人數達 34 人（4.68%）。此數據表明，儘管救難案件數相較於前兩年（民國 112 年與 113 年）的高峰期略有回落，但整體仍處於高原期，顯示出建構更完善的山野安全防護與高效救援機制，具備高度的迫切性與實務研究價值。

深入分析山域事故之成因，官方統計之直接主因前三名依序為迷路（205 件，38.61%）、創傷（103 件，19.40%）以及墜谷（43 件，8.10%）；而直接歸因於生理疲勞之案件則有 42 件（7.91%）。然而，多數表面上的迷路、創傷或墜谷，其背後往往隱藏著「生理疲勞」這一核心的隱性內在成因。相關研究指出，人為因素中的疲勞累積、風險判斷失誤與決策錯誤，是造成可避免山域事故的重要原因之一 [1]。

尤有甚者，統計資料指出在各類事故族群中，以「自組隊伍」的身分類別佔比最高，達 406 人（55.85%）。在群體登山的動態環境下，常存在著複雜的心理博弈：許多登山者在體力已達臨界極限時，因害怕行進進度落後或擔心成為團隊包袱，往往選擇刻意隱瞞或忽視自身早已透支的疲勞狀態。這種「同儕壓力」導致群體中的危險因子被無形放大，無法及時被隊友察覺。在長途跋涉過程中，長期且被忽視的生理消耗會直接導致肌肉力量下降與中樞神經系統運作遲緩。在生理與生物力學層面上，股四頭肌等核心肌群的深度疲勞會顯著改變人體的步行姿態，降低身體對不平整地形的調節能力，大幅提高失足與滑倒的機率 [2]；在心理與認知層面上，生理耗損疊加高海拔的低氧環境，易引發大腦認知功能失調與空間適應策略失效，使登山者在關鍵時刻做出錯誤的風險評估，甚至在複雜地形中喪失方向感而誤入迷途 [3]。由此可知，疲勞實為催化迷路與墜谷等顯性事故的底層變數，故現行缺乏客觀、非侵入式之即時監測技術，是當前登山安全防護上急需解決的核心問題。

然而，即便在事故發生後，現行的山域搜救實務仍面臨嚴重的地形盲區與通訊中斷等技術瓶頸。山區地形崎嶇且危險區域（如深谷、峭壁邊緣、密林）密布，且多數高山區域處於行動網路之通訊盲區。搜救人員在執行任務時，基於自身安全風險與搜救時效的雙重考量，通常僅能對高風險區域進行重點式或目視性的快速巡查，難以在毫無線索的情況下進行地毯式的窮舉搜索，這不僅增加搜救人員自身的墜落風險，也極易在缺乏具體跡象時略過隱蔽的地形盲區。

此實務瓶頸在現實案例中往往導致悲劇。以民國 115 年（2026 年）於南投西巒大山發生的一起獨攀墜谷案件為例，受難者在不慎墜落深達 250 公尺的深谷後，當下意識清晰並成功向家屬發送求救訊息。然而，由於高山通訊限制，該訊息未能附帶精確的空間坐標，導致搜救隊伍在廣袤且地形險峻的危險區域中，難以在第一時間鎖定其確切位置。即便搜救人員已推進至受難者附近的地形邊緣，也極可能因視覺死角、地形阻隔或受難者體力耗盡無法大聲呼救，而未能察覺其存在，最終導致搜救行動錯失黃金救援時間，

受難者不幸罹難。

綜上所述，現行山域安全機制與救援流程存在兩大重大痛點：

1. **災前預警機制的缺乏**：現行缺乏客觀、非侵入式的即時生理與步態疲勞監測手段，無法在登山者體力耗盡、步態失穩前發出主動預警，以防範墜谷與迷路於未然。
2. **災後搜救的通訊與定位盲區**：當事故發生在無行動網路訊號之深山、且受難者受困於視覺盲區時，即使受難者仍具備清晰意識，搜救隊伍也因缺乏局部微觀的雙向互動手段，導致搜救人員在推進至附近時仍與受難者擦身而過。

因此，當前登山安全領域的關鍵需求在於：如何從「災前的主動疲勞監測」到「災後的跨地形主動求救」進行系統性的技術整合，以打破地形死角並突破通訊盲區，實為提升山域救援成功率與保障登山者生命安全亟待解決的關鍵課題。

(二)文獻回顧

許多山域事故常受到疲勞累積、認知能力下降及決策失誤等人因因素的共同影響。在可避免的山域事故中，人為因素往往占有相當比例，其中疲勞與錯誤決策皆為主要原因 [1]，而迷途與體力耗盡更是最常見的事故因素 [4]，其與環境因素的交互作用更是戶外活動的核心潛在風險 [5]。從生理機制角度來看，運動疲勞涉及代謝產物累積、神經傳導效率下降以及肌肉功能退化等生理變化 [6]。當疲勞持續累積時，中樞神經系統與周邊神經肌肉系統會使肌肉輸出能力逐漸下降 [7]，在長時間山區運動中造成顯著的神經肌肉疲勞並使下肢最大自主收縮能力明顯降低 [8]，進而引發局部缺氧與血流供應不足 [9]。除肌肉疲勞外，背負重裝備時胸廓受到壓迫會增加呼吸肌負擔 [10]，高強度運動造成的橫膈膜疲勞亦會降低換氣效率並影響整體運動表現 [11]。這些生理層面的衰退會直接體現在步態與認知控制上，例如股四頭肌疲勞會顯著改變人體步態特徵，降低下肢對不規則地形的適應能力，進而大幅提高滑倒與跌倒的風險 [2]，而高海拔環境所帶來的低氧效應亦會引發注意力下降與決策能力減弱，使登山者更容易因方向判斷錯誤而迷途 [3]。總體而言，身體疲勞會導致步幅縮短、步態週期改變與行走穩定性下降 [12]，增加身體晃動幅度並降低平衡控制能力 [13]，其所提高的步態變異性更使跌倒風險顯著增加 [14]。全身性疲勞亦會大幅降低人體的姿勢控制與平衡能力 [15]，且當疲勞累積與坡度增加時，使用登山杖的登山者會主動改變登山杖與雙腳之間的協調模式以維持行走穩定性 [16]。

為了有效評估並精準偵測上述步態變化與疲勞狀態，近年來以慣性測量單元 (IMU) 為核心的穿戴式感測技術被廣泛應用。IMU 具備體積小、成本低及容易部署等優勢，能藉由加速度計與陀螺儀有效辨識人體活動型態與運動狀態 [17]，並已被證實能夠精確量測自由行走環境中的步態特徵 [18] 以建立跌倒風險評估模型 [19]。在疲勞辨識的實務中，將慣性感測器蒐集之時序步態數據結合深度學習模型，能成功區分不同的疲勞階段 [20]。隨著人工智慧技術的發展，深度學習模型已被證實能有效從大量時序資料中學習疲勞特徵，例如利用生理訊號建立多層級疲勞分類系統 [21]、執行疲勞偵測 [22]，或利用 GPS 時序資料預測運動疲勞程度 [23]。由於步態與疲勞狀態具有高度時間連續性，長短期記憶網路 (LSTM) 透過記憶單元與遺忘閥機制改善了長時間序列建模的長期依賴問題 [24], [25]；而門控循環單元 (GRU) 則

利用更新閘與重置閘機制保留重要資訊，在維持媲美 LSTM 性能的同時減少了參數與運算成本 [26], [27]，其結合 CNN 或注意力機制的架構在疲勞偵測中均獲得良好的辨識效果 [28], [29]，極適合部署於邊緣設備進行即時步態分析。另一方面，為因應步態失穩導致事故後的搜救需求，傳統 VHF/UHF 無線電系統雖具備良好穿透力 [30]，但新興的軟體定義無線電 (SDR) 技術能透過軟體進行頻率與通訊協定重構 [31]，其高度彈性與多頻段支援能力非常適合建立具韌性的災害緊急通訊系統 [32], [33] 或應用於無人機搜救以提升定位效率 [34]。在射頻與音訊訊號辨識上，卷積神經網路 (CNN) 能有效從轉換後的頻譜圖中萃取關鍵特徵並進行高準確率分類 [35]，且輕量化 CNN 模型已被證實可部署於邊緣設備以兼顧低功耗與即時推論需求 [36]。因此，整合 IMU 步態感測、邊緣端 GRU 疲勞預警、SDR 無線電與輕量化 CNN 訊號辨識技術，成為當前偵測高山步態變異與應對突發事故的重要技術路徑。

二、 專題簡介

為有效解決上述因疲勞誘發山難以及深山通訊盲區導致救援失敗的實務痛點，本研究開發了一套「結合 IMU 與 AI 疲勞監測之登山安全輔助系統」。本系統旨在透過軟硬體整合技術，建構「災前零負擔精準預警」與「災後突破地形屏障」的全面性山域安全防線，其整體架構與核心技術主要由以下三個維度組成：

(一) 疲勞預警系統

在硬體端，本系統捨棄了市面上常見、需多點穿戴且操作繁瑣的穿戴式感測裝置，創新採用非侵入式設計，將六軸慣性感測器 (IMU) 直接整合至登山者必備的單一登山杖中，免除使用者額外的穿戴負擔。針對學界缺乏高山步態公開資料集的痛點，本團隊實地攀登並採集了 20 小時之真實高山步態數據，建構出專屬的時序資料庫。為了大幅提升模型的泛化能力與辨識精度，系統導入生成式擴增模型 (Diffusion Model) 進行時間序列數據增強，並結合自適應調適 (Domain Adaptation) 機制，有效克服了不同使用者個體差異以及多變地形對步態訊號造成的干擾。在演算法核心部分，本系統於後端導入門控循環單元 (GRU) 深度學習模型，即時分析三軸加速度與三軸陀螺儀訊號，精準萃取攀登者的步伐頻率、步態對稱性與動態穩定度等生理疲勞特徵。經實測，該模型對於登山者疲勞狀態的整體辨識準確率高達 98.87%，能於邊緣端實現高效、精準的疲勞狀態定量評估。

(二) SDR 緊急通訊救援系統

針對高山地區缺乏行動網路基地台，且受難者可能因墜谷或受困於視覺盲區導致搜救困難的窘境，本系統創新整合了軟體定義無線電 (SDR) 被動接收技術與 2D CNN 音訊與訊號辨識模型。考量無線電發射受限於法規與實務設備限制，本系統採取「被動掃描廣播，主動聲音示警」的逆向救援邏輯。

當受難者處於待援狀態時，隨身攜帶的低功耗 SDR 接收端會持續全面掃描 VHF (144–146 MHz) 與 UHF (430–440 MHz) 等官方法定搜救與業餘無線電頻段。此機制能有效克服複雜山域地形與茂密植被覆蓋所帶來的嚴重訊號衰減。當搜救隊伍推進並於上述頻段內發射搜索訊號時，一旦系統在最遠達 300 至 500 公尺的距離



圖 1. 疲勞辨識系統整體流程圖



圖 2. 三汀山數據採集路線



圖 3. 大坑數據採集路線

內自動偵測並精準識別出微弱的無線電特徵，便會即時觸發行動端應用程式 (APP) 發出高分貝的應急警報聲。透過此主動發聲機制，受難者可在體力耗盡、無法大聲呼救的情況下，利用手機音訊成功吸引搜救隊員的注意，引導搜救人員鎖定其隱蔽位置。

(三) 行動端應用程式 (APP)

本專題最終將上述核心功能與前端用戶介面進行深度整合，開發出專屬的登山安全輔助手機 APP。該應用程式集成了離線地圖導航、即時氣象預報、動態步態疲勞監測演算法示警，以及 SDR 緊急無線電求救控制開關。透過友善的圖形化介面，系統不僅能在攀登者發生滑倒或迷路危機前，主動發出視覺與聽覺的疲勞預警，提醒登山者適時紮營或休息；亦能在意外不幸發生時，提供跨越地形屏障的應急通訊備援。本系統透過「智慧感測登山杖」與「無線電求救網路」的雙軌架構，實現了從自主防護到協同救援的閉環機制，切實解決了現行山域安全中疲勞難以監測、危險區域難以搜索的技術盲點，為山林探險者提供了兼具災前防範與災後救援的系統化解決方案。

三、製作理論探討

(一) 疲勞預警系統

本章旨在闡述「疲勞預警系統」之核心架構(如圖 1.)與技術實現路徑。本系統採用軟硬體整合架構，將慣性感測技術整合於單一登山杖中，建立自數據採集、前處理擴增、邊緣端模型推理至跨使用者動態校準之完整系統，本系統之關鍵技術與其實現路徑主要涵蓋以下四個維度：

- 實地數據採集與生成式擴增：針對高山步態公開數據匱乏之現況，本研究實地採集逾 20 小時之真實高山步態數據，並導入去噪擴散機率模型 (DDPM) 與啟發式特徵擾動策略，以擴充訓練樣本之

多樣性、排除數據不平衡，並提升模型之泛化效能。

- 實時雙向人工標記與多分類設計：採用全程實時人工標籤切換機制，確保時序訊號與受試者之真實生理狀態精確對齊。同時引入「其他 (Other)」類別以涵蓋非標準撐杖動作，提升系統於實際應用中之排他性與防誤報能力。
- 輕量化邊緣深度學習模型：考量嵌入式設備之運算與記憶體資源限制，本研究設計深而窄之三層門控循環單元 (GRU) 網路，以極小化之參數規模與低運算負載，有效擷取連續多維度時序特徵。
- 無監督領域自適應即時校準：整合 CORAL 領域自適應演算法，由伺服器端預先提取基準領域分佈特徵，並於邊緣端透過低耗能之矩陣運算進行實時特徵對齊，消弭因個體行為與地形差異所造成之領域偏移 (Domain Shift)，實現隨插即用 (Plug-and-Play) 之個人化校準。

以下將針對數據採集環境、硬體配置、標籤註記流程、前處理與增強策略，以及模型優化與邊緣端部署架構進行逐一論述。

1. 數據來源與採集環境

鑑於學術界目前缺乏針對高山攀登步態與智慧登山杖感測之公開時序數據集，本研究之數據均由研究團隊進行野外實地採集。野外山域之數據蒐集面臨高度的硬體與環境限制：在本研究之原型階段，僅配置兩根掛載嵌入式感測硬體之智慧登山杖原型機，無法進行群體並行採集；且真實山徑之碎石擾動、陡坡摩擦力與生理代償行為無法於室內跑步機模擬，必須由實驗人員親自實地攀登。

在受限於硬體數量、體能極限、天候窗口與險峻地形的條件下，團隊歷時長期外測，成功累積總時長逾 20 小時之高品質真實高山步態時序數據。整體數據庫嚴格區分為訓練數據集 (Training Dataset) 與測試數據集 (Testing Dataset)：

(1) 訓練數據集 (Training Dataset) 之採集佈署

主體採集場域 (三汀山步道) (如圖 2.)。該路段鄰近研究單位且具備高度地形多樣性，空間地貌涵蓋緩坡、陡坡、人工階梯 (石階與木棧道) 以及未鋪設的原始碎石路面，利於模型學習不同地表特徵下的步態特徵，避免對單一路面過擬合。

數據擴增場域 (大坑步道) (如圖 3.) 進行數據補強。利用其特有的連續陡峭階梯與多變坡度，優化深度學習模型在多變攀登節奏下的辨識穩定度。

(2) 測試數據集 (Testing Dataset) 之採集佈署

用於評估模型在「跨主體 (Cross-subject)」與「跨地理環境 (Cross-environment)」下的泛化效能，採完全獨立於訓練集的配置：

跨地理環境驗證：場域涵蓋橫嶺山主峰 (中海拔原始林道)、馬那邦山 (多沙礫泥土路面)

跨主體多樣性驗證：邀請多位非受訓之同學協助採集。透過引入不同體態與攀登習慣的真實步態訊號，嚴格檢驗

系統之泛化效能。

(3) 地形覆蓋度與採集限制說明

儘管研究團隊在數據採集規劃中，已盡可能涵蓋臺灣山域常見的多樣化地貌，以最大化訓練數據之環境多樣性；然而，受限於野外實地外測之極高成本、體能極限與天候窗口等不可抗力因素，數據集仍可能存在部分邊緣地形或特殊地表特徵之覆蓋缺漏。此一現實限制，亦為本研究於後續章節導入生成式演算法（如 Diffusion Model）進行時序數據增強的核心動機，旨在透過生成式模型彌補真實樣本在極端分佈上的不足。

2. 採集硬體配置與訊號維度篩選

(1) 本研究選用智慧登山杖作為感測主軸之核心邏輯

目前市面上針對運動或攀登狀態之監測，主流仍以穿戴式智慧手環或手錶（擷取心率與手腕 IMU 訊號）為主。然而，本研究捨棄手環而選用登山杖作為時序訊號採集主軸，係基於行為特徵收斂性與邊緣端分類可行性之考量。

智慧手環在實際登山過程中，極易受到受試者多元且隨意的手部動作干擾（如隨意擺手、擦汗、拿取物品、調整裝備等非結構化行為），導致其產生的 IMU 訊號特徵高度雜亂且難以歸納，模型極易將上述動作誤判為疲勞或正常步態之變異。相對地，登山杖在攀登過程中受限於與地面的物理支撐需求，其動態軌跡與力學行為架構相對單一且具備高度規律性。受試者在「正常」與「疲勞」狀態下的撐杖節奏、落點衝擊力道與空間揮動軌跡，具備高度可預測的物理變異。因此，利用登山杖數據能有效過濾非目的性的肢體雜訊，使深度學習模型能更精確地聚焦於疲勞誘發的步態特徵變異。

(2) 硬體端架構與參數配置

本研究設計之智慧登山杖嵌入式感測模組原型(如圖 4.)。系統以高性價比、具備無線通訊能力之 ESP32 微處理器為運算核心，核心感測元件採用 SparkFun BNO086 九軸慣性測量單元（IMU）。

該模組透過微型化機構設計，整合高容量藍色鋰離子電池組與外接充電接口，並以非侵入式之高透明度壓克力保護外殼，緊密且穩固地夾持固定於登山杖上端之擺動軸心處，以最大化接收手腕傳導之運動慣性。BNO086 的時序數據採集頻率設定為 160 Hz，以完整保留高頻步態衝擊與撐杖瞬態特徵。

(3) 訊號維度篩選與降維決策

系統原始錄製包含三軸線性加速度、三軸陀螺儀角速度、三軸地磁計與四元數動態姿態角。考量邊緣端（Edge AI）運算資源、電池續航力與無線通訊頻寬限制，本研究於模型輸入端進行特徵維度篩選，最終僅保留並回傳三軸加速度與三軸陀螺儀（總計六軸）之時序訊號。




圖 4. 登山杖嵌入式感測模組原型




圖 5. 感測器方向




圖 6. 數據蒐集流程




圖 7. 正常狀態




圖 8. 疲勞狀態

此降維決策之依據在於，攀登者的生理疲勞特徵已能充分表徵於下肢落地傳導至上肢的加速度衝擊振幅，以及撐杖時的角速度空間擺動。剔除易受山區礦石地磁干擾的磁力計與運算繁瑣的四元數，能大幅降低邊緣端深度學習模型（如 GRU）的運算負載，實現離線即時辨識。

(4) 感測器安裝角度與位置之影響探討

本系統六軸慣性感測器（IMU）之配置，在安裝角度與位置上均與常規幾何基準有所差異，此設計對資料判讀具備特定物理與演算法機制之影響。

在安裝角度方面，本系統採用非標準之偏角配置(如圖 5.)，主要係為了與登山者實際「斜向撐杖推進」之生理學

動態軌跡進行空間對齊。常規的水平或垂直安裝在面對非垂直受力時，易產生嚴重的交叉軸干擾（Cross-Axis Sensitivity）；透過調整至此特定偏角，能使前向推進與側向晃動之動態特徵直接映射至感測晶片靈敏度最高之軸向，使疲勞引發的步態不對稱性與代償行為在特徵空間中更具辨識度。

在安裝位置方面，感測器固定於登山杖上端握把下方，而非中段或杖尖。此位置可利用杖體材質作為天然的低通物理濾波器，有效吸收杖尖撞擊碎石路面所產生的高頻衝擊波與機械諧振，防範加速度計訊號瞬間飽和（Clipping）之現象。

雖然非標準角度使原始訊號之分量與絕對座標系存在偏差，但本研究導入之門控循環單元（GRU）深度學習模型，能於滑動窗口時序資料中自動調適並擷取此固定偏角下之相對特徵演變，使邊緣端推理系統具備良好的即時感知能力。

3. 疲勞狀態定義與實時人工標籤切換機制

因攀登者肌肉耐力、體態與撐杖習慣具個體差異，本研究捨棄固定的物理閾值，採「全程實時人工標籤切換機制（Real-time Manual Label Switching Mechanism）」。在單次行程中系統保持不間斷錄製，由隨行人員依據客觀行為與生理指標，動態切換數據標籤。

(1) 人工標記之疲勞行為特徵與觀測指標

判定受試者進入生理疲勞狀態並執行「標籤切換」之五大核心特徵如下：

- a. 步伐頻率下降
- b. 步伐穩定性降低
- c. 登山杖揮動規律性下降
- d. 身體與杖體晃動幅度增加
- e. 心率持續處於生理高位

(2) 實時人工雙向標籤切換與資料註記流程

為了在不中斷硬體時序錄製（160 Hz）的前提下，精確註記二元分類標籤（正常 Normal, 0 vs 疲勞 Fatigue, 1），本研究實施具備「動態雙向修正」之標準化人工標記流程（如圖 6.）。

(3) 正常與疲勞狀態之原始數據特徵對比

- a. 走路頻率顯著下降（週期拉長）
- b. 時序訊號規律性降低與雜訊代償

實時人工標籤切換機制截取的時序訊號，在「正常」與「疲勞」狀態下具有顯著的量化波形差異（如上述 a、b 特徵）。這實證了該機制能精確切分出具備高信度的步態特徵，為後續 AI 模型訓練奠定具高區別性的資料基礎（如圖 7.-圖 8.）。

(4) 模型訓練之三分類擴展與非典型動作排除（Other Class）

雖然在野外實地採集階段，基於人力監測限制，隨行人員僅針對「正常（notTired）」與「疲勞（Tired）」兩類核心步態進行二元標記；但在實際邊緣端部署應用時，使用者不可能在行進間始終維持標準的撐杖推進動作。攀登過程中必然伴隨諸如短暫停頓時的杖體亂甩、調整手腕織帶、手持杖體離地揮動或放置休息等非典型隨機動作。

若僅以二元分類模型進行推理，此類未定義的雜亂訊號極易落入正常或疲勞的模糊決策邊界，導致系統產生頻繁誤報。為提升模型在現實複雜場景下的穩健性與排他能力（Reject Capability），本研究在實作模型訓練時，特別引入了第三個數據類別——「其他（Other）」。此類別基礎數據涵蓋了上述各類隨機、非標準撐杖的異常訊號。透過三分類模型之架構訓練，使邊緣端系統具備識別非結構化動作的能力，唯有當訊號符合標準撐杖軌跡且達疲勞指標時方進行預警，大幅降低現實應用中的誤判率。

(5) 資料前處理與增強策略 (Data Preprocessing and Augmentation)

在感測器訊號（IMU）的深度學習任務中，訊號的穩定性與多樣性直接影響模型的泛化能力。本研究針對收集到之加速度計與陀螺儀六軸時間序列訊號，設計了一套標準化前處理流程，並針對不同類別（notTired、Tired、Other）

制定了分級資料增強策略，結合傳統啟發式方法與深度生成模型，以提升分類器之強健性。

4. 資料前處理 (Data Preprocessing)

(1) 滑動窗口分割 (Sliding Window Segmentation)

本研究硬體採樣頻率設定為 160 Hz。為捕捉完整的步態週期，我們採用滑動窗口技術將連續的時間序列訊號切割為固定長度的樣本。

經步態分析指出，單次登山杖使用的最長耗時通常落在 6 秒以內。因此，本研究將窗口長度（Window Size）設定為 960 據點（即 6 秒 × 160 Hz 6 秒 × 160 Hz），確保每個樣本內至少涵蓋一個完整的步伐特徵。同時，為增加樣本數量並保留時序上的連續性，窗口移動步長（Step Size）設定為 480（即 50% 重疊率）。

(2) 全域標準化 (Global Z-Score Normalization)

為消除不同感測器與不同物理量（加速度與角速度）之間的量綱與數值級距差異，避免單一特徵主導模型梯度更新，本研究於資料輸入模型前實施全域標準化。

有別於單一樣本獨立計算，本研究先將所有訓練集訊號攤平，計算出各通道之全域平均值（Global Mean, μ ）與全域標準差（Global Standard Deviation, σ ）。隨後以此全域參數對訓練集、驗證集與測試集進行 Z-Score 正規化，公式如 4-2：

$$x' = \frac{x - \mu}{\sigma + \epsilon} \quad (4-2)$$

表 1.各類別資料增強策略總覽

	原始數據	$\sigma = 0.3$ 雜訊增強	$\sigma = 2.0$ 雜訊增強	Diffusion Model 生成	總計	懲罰 權重
notTired	1179	1179	-	1000	3358	0.84
Tired	1299	1299	-	-	2598	1.09
Other	78	-	2478	-	2556	1.11




圖 9. 原始波形(加速度)




圖 10. 原始波形(陀螺儀)




圖 11. $\sigma = 0.3$ (加速度)




圖 12. $\sigma = 0.3$ (陀螺儀)




圖 13. $\sigma = 2.0$ (加速度)




圖 14. $\sigma = 2.0$ (陀螺儀)

表 2.參數配置

	類別	參數	引用圖號
輕度增強	notTired Tired	$S = 1.1$ $\sigma = 0.3$	圖 11.-12.
極端增強	Other	$S = 1.2$ $\sigma = 2.0$	圖 13.-14.

此作法不僅能使數據符合標準常態分佈，亦為後續邊緣端（Edge Device）部署保留了固定的校正參數，確保推論階段與訓練階段的數據分佈尺度一致。

(3) 分級資料增強策略 (Hierarchical Data Augmentation Strategy)

為解決實務中可能面臨的類別不平衡問題，並提升模型對於未知雜訊（Out-of-Distribution）的抵抗力，本研究針對 notTired（未疲勞）、Tired（疲勞）以及 Other（非步態/異常動作）三個類別，分別實施不同程度與方式的資料增強(如表 1.)。

(4) 啟發式特徵擾動 (Heuristic Perturbation)

本研究透過在原始訊號(圖 9.-10.)中注入高斯雜訊 (Gaussian Noise) 與振幅縮放 (Amplitude Scaling)，模擬真實環境下的感測器晃動與使用者動作變異，公式如(4-3)：

$$x_{aug} = (x \times S) + \mathcal{N}(0, \sigma^2) \quad (4-3)$$

其中 S 為縮放係數， σ 為高斯雜訊之標準差，參數配置如表 2 所示。

5. 基於擴散模型之深度生成增強 (Deep Generative Augmentation via DDPM)

為解決實地採集之基準狀態 (notTired) 原始樣本規模有限之限制，本研究於前置階段導入去噪擴散機率模型 (Denoising Diffusion Probabilistic Model, DDPM) 進行數據增強，以進一步拓寬步態特徵空間之多樣性。

在網路架構設計上，本研究採用如圖 15. 所示之一維條件式 U-Net (Conditional UNet-1D) 結構作為核心網路，於輸入端整合 6 軸 IMU 訊號、時間步長嵌入 (Time Embedding) 與類別條件嵌入 (Label Embedding)。為消除時間序列生成中常見的邊界突刺效應 (Checkerboard Artifacts)，本研究優化其轉置卷積機制，將傳統一維轉置卷積 (ConvTranspose1d) 替換為「上採樣 (Upsample) 搭配一維卷積 (Conv1d)」之組合，並引入殘差連接 (Residual Connections)，以保障合成波形之平滑度與物理連續性。

在模型訓練與收斂規範方面，前置訓練之擴散步長 (Timesteps) 設定為 1000 步，並採用 Adam 優化器最小化均方誤差損失 (MSE Loss)。模型歷經 500 個 Epochs 訓練後順利收斂，其訓練損失曲線如圖 16. 所示。

完成前置訓練後，模型透過逆向去噪過程 (Reverse Denoising Process) 成功生成 1,000 筆具備真實步態特徵分佈之 notTired 合成樣本，其生成波形分別如圖 17 與圖 18 所示。在模型訓練的數據擴充策略上，此 1,000 筆合成數據被獨立導入作為後續分類器的訓練特徵集。透過此增強機制，使參與分類模型訓練的基準狀態 (notTired) 樣本規模由原始的 1,179 筆 (訓練分配額) 擴充至 2,179 筆 (詳細數據結構如表 1 所示)，藉此提升模型訓練的泛化度與抗過擬合能力，而無須更動或污染既有的原始步態觀測數據庫。

6. 模型訓練與優化策略 (Model Training and Optimization Strategy)

(1) 交叉驗證與資料切分策略 (Cross-Validation and Data Splitting Strategy)

為客觀評估核心分類器之泛化效能，本研究導入 5 折交叉驗證機制 (5-Fold Cross-Validation)，並採取「時空完全隔離」與「先劃分、後增強」之封閉式動態配置，以嚴格防止資料洩漏 (Data Leakage)。



圖 15. Diffusion 模型架構




圖 16. Diffusion 模型 Training Loss 曲線圖




圖 17. 生成數據(加速度)




圖 18. 生成數據(陀螺儀)

首先，本研究將獨立測試集進行時空隔離，使其完全不參與訓練擬合。該測試集包含兩大來源：一是專題作者於野外另行採集之跨時間樣本（其日期、天候與行進節奏均與訓練集不同）；二是邀請未參與訓練之異源使用者（如 A 同學、B 同學）實地採集之跨主體樣本（如圖 2. 與圖 3. 所示），用以檢驗系統之模型穩健性與個體泛化極限。

排除獨立測試集後，包含預先生成數據在內共計 8512 筆之基礎資料庫（詳見表 1「總計」欄位），被隨機且均勻切分為 5 個互斥子集（Folds）。在每輪迭代中，4 個子集



圖 19. 模型架構示意圖

表 3. GRU 模型架構與訓練超參數配置表

Parameter	Value
Layers	3
Hidden	16
Dropout	0.2
Optimizer	Adam
Learning Rate	0.003
Batch Size	1024

(80%) 作為訓練折 (Training Folds)，剩餘的 1 個子集 (20%) 則作為驗證折 (Validation Fold)。

為確保驗證折之純淨度，特徵擾動程序僅在訓練折內部動態觸發。系統針對訓練折內之數據執行輕度擾動 (notTired 與 Tired 注入高斯雜訊與振幅縮放)，並進行極端擾動 (注入雜訊以建構 Other 負樣本，波形如圖 11. 至圖 14. 所示)；當前輪次之驗證折則嚴格隔離於所有雜訊注入程序之外，以確保分類邊界評估之真實性。

(2) 輕量化模型架構與超參數配置 (Model Architecture and Hyperparameter Configuration)

為配合邊緣端 (Edge Device) 硬體之運算與記憶體限制，本研究採用「深而窄」之三層門控循環單元 (Gated Recurrent Unit, GRU) 作為核心分類器。模型訓練階段之資料流 (如圖 19. 所示) 規格定義如下：

- 多通道數據輸入：接收經滑動窗口分割 (6 秒、50% 重疊率，共 960 點) 之 6 軸時序訊號。
- 全域 Z-Score 正規化：依據公式 (4-2) 提取之通道平均值與標準差，對輸入數據進行尺度對齊。
- GRU 特徵擷取：透過三層 GRU 網路 (每層堆疊 16 隱藏單元，搭配 Dropout 0.2) 擷取長短期時序相依性。
- Softmax 類別映射：經全連接層後，利用 Softmax 函數將輸出映射為三維之類別機率分佈。
- 多指標評估輸出：根據分類機率輸出預測結果，並進行多項核心指標之綜合評估。(註：此流程中暫不啟用 CORAL 領域特徵轉換與自適應動態閾值判定兩項推理端模組)。

本研究分類器之結構參數、正則化機制與訓練超參數配置詳見表 3。

(3) 損失函數與類別權重平衡 (Loss Function with Class-Weight Balancing)

鑑於各類別在樣本規模上與原始數據存在顯著不平衡（如表 1 所示），本研究導入反頻率加權機制（Inverse Frequency Weighting）校正類別權重。其各類別損失權重 W_c 定義如公式 (6-3) 所示：

$$W_c = \frac{N_{total}}{C \times N_c} \quad (6-3)$$

其中 N_{total} 為該輪訓練集總樣本數， $C = 3$ 為類別總數， N_c 為特定類別之樣本數量。透過此動態權重矩陣懲罰少數類別之誤判，以提升多分類交叉熵損失（Cross-Entropy Loss）在不平衡邊界上的客觀性。

(4) 邊緣端部署基準統計量提取 (Baseline Statistical Extraction for Edge Deployment)

本研究為無監督領域自適應（Unsupervised Domain Adaptation，如 CORAL 演算法）建立前置運算基礎。由於邊緣端設備運算力受限，本研究將基準領域特徵足跡（Source Domain Footprint）的提取工作移至伺服器端（Server Master）於訓練完成後一併執行。

該階段旨在提取源領域（基準狀態：未疲勞 notTired）的二階統計分佈特徵，其步驟如下：

a. 全域參數標準化 (Global Normalization)

自源領域訓練集中提取所有類別之樣本，於通道維度計算全域均值向量 μ_{global} 與標準差向量 σ_{global} ，並對原始特徵矩陣進行 Z-Score 正規化。

b. 基準特徵中心化 (Feature Centering)

篩選標準化後屬於未疲勞狀態（notTired）的基準特徵矩陣 $X_{src} \in \mathbb{R}^{M \times D}$ 。計算其多通道基準均值向量 $\mu_{src} \in \mathbb{R}^{1 \times D}$ ，公式如下(6-4-1)：

$$\mu_{src} = \frac{1}{M} \sum_{i=1}^M X_{src,i} \quad (6-4-1)$$

c. 協方差矩陣估算與正定性調整 (Covariance Estimation & Regularization)

計算基準特徵之協方差矩陣 $\Sigma_{src} \in \mathbb{R}^{D \times D}$ 。為避免矩陣奇異並確保其嚴格正定，引入微小擾動項 $\epsilon = 1 \times 10^{-5}$ ，公式如下(6-4-2)：

$$\Sigma_{src} = \frac{1}{M-1} (X_{src} - 1\mu_{src})^T (X_{src} - 1\mu_{src}) + \epsilon I \quad (6-4-2)$$

d. 奇異值分解與矩陣平方根重構 (SVD & Matrix Square Root Reconstruction)

對正定協方差矩陣 Σ_{src} 進行奇異值分解，公式如下(6-4-3)：

$$\Sigma_{src} = USV^T \quad (6-4-3)$$

對奇異值矩陣 S 設置安全下限 $\tau = 1 \times 10^{-6}$ 以防範數值奇異點，並重構得矩陣正平方根 $\Sigma_{src}^{1/2}$ ，用以後續邊緣端之線性轉換，公式如下(6-4-4)：



圖 20. 模型架構示意圖

$$\Sigma_{src}^{1/2} = U \text{diag} \left(\sqrt{\max(S, \tau)} \right) V^T \quad (6-4-4)$$

e. 輕量化參數封裝 (Deployment Packaging)

將全域標準化參數 ($\mu_{global}, \sigma_{global}$) 與基準特徵足跡 ($\mu_{src}, \Sigma_{src}^{1/2}$) 封裝為輕量化佈署檔 (edge_deployment_stats.pth)。當其與輕量化之 GRU 權重模型聯合部署於嵌入式設備時，邊緣端即可僅依靠低耗能矩陣乘法，即時將異質使用者的感測器訊號與訓練期基準分佈對齊。

7. 邊緣端部署與即時領域自適應 (Edge Deployment and Real-Time Domain Adaptation)

(1) 邊緣端雙層級自適應推論架構

當輕量化模型部署至嵌入式終端設備後，為消弭跨使用者間的步態分佈偏移，本研究在推論階段導入一套「雙層級領域自適應 (Two-Level Domain Adaptation)」框架。系統運作流程(如圖 20.)，核心聚焦於輸入特徵的線性對齊與決策邊界的動態修正。

- 前置特徵擷取 (步驟 1~3)：即時 IMU 訊號經標準化後，由 GRU 提取核心時序特徵，隨即進入自適應核心模組。
- 第一層：輸入特徵級自適應 (步驟 4 CORAL 領域特徵轉換)：載入伺服器端預先計算之源領域統計足跡 (均值 μ_{src} 、協方差矩陣開根號 $\Sigma_{src}^{1/2}$)，對目標特徵進行無監督線性對齊：

$$X_{aligned} = X_{norm} W_{align} + b_{align}$$

轉換矩陣 W_{align} 與偏置 b_{align} 僅涉及基礎矩陣乘加運算 (No Retraining)，完美契合邊緣設備的低功耗限制。

- 第二層：決策邊界級自適應 (步驟 5~6 自適應動態閾值信心判定)：對齊後的特徵經 Softmax 計算機率。決策端利用初始化校正期收集之未標註數據，提取其預測分佈之第 5 百分位數 (P_5) 動態計算專屬分類閾值 (Th)，介入修正 notTired 與 Tired 的判定邊界。
- 指標輸出 (步驟 7)：最終輸出經雙層自適應完全校準後之即時偵測結果。

(2) 四階段自適應評估狀態劃分

依據硬體計算資源與自適應層級之啟用差異(對應圖 1 流程之不同路徑)，本研究將評估狀態劃分為以下四種架構，




圖 21. 模型架構示意圖



圖 22. 數據採集地點(三汀山)



圖 23. 軟體定義無線電模組

用以逐層驗證校準成效：

- BASE (無自適應基準)：**數據流跳過步驟 4 與步驟 6。特徵擷取後直接進行標準 Argmax 分類，用以觀測未經校正前的原始領域偏移。
- BASE_ADAPT (僅信心度自適應)：**數據流跳過步驟 4，僅啟用步驟 6。直接利用動態閾值 (Th_{base}) 修正決策判定邊界。
- CORAL (純特徵線性對齊)：**數據流啟用步驟 4，但跳過步驟 6。特徵經線性轉換對齊至源領域分佈後，進行標準 Argmax 推論。
- ADAPT (特徵線性對齊 + 動態閾值調整)：**完整啟用步驟 1 至步驟 7。結合 CORAL 特徵對齊與動態信心度閾值 (Th_{adapt}) 進行雙層級完全校準。

(二) SDR 緊急通訊救援系統(對講機音訊辨識模型)

本章旨在闡述「SDR 應急通訊救援系統」之數據採集方法、數位訊號處理流程與 AI 識別模型之實現路徑(如圖 21.)。本系統針對深山無行動網路訊號之搜救困境，創新整合軟體定義無線電 (SDR) 技術與二維卷積神經網路 (2D CNN)，建構具備高穿透性與弱訊號自動偵測能力之局部微觀雙向互動機制。

本系統之關鍵技術與其實現路徑主要涵蓋以下四個維度：

- **實地無線電數據採集：**選定植被密布且地形複雜之三汀山作為實測場域，使用實體對講機與 SDR 模組，針對特高頻 (VHF 145.3 MHz) 與超高頻 (UHF 432.6 MHz) 頻段進行 50 至 500 公尺之直線距離傳輸測試，用以分析真實山區之訊號衰減特性。
- **時頻轉換與頻譜特徵工程：**對原始 256 kHz 採樣率之同相與正交 (I/Q) 數據進行 8 倍降採樣 (Decimation) 以濾除冗餘雜訊，隨後運用短時距傅立葉變換 (STFT) 將一維時域複數訊號轉換為二




圖 24. 訓練集正樣本示意圖




圖 25. 訓練集負樣本示意圖

維分貝尺度頻譜圖，並導入 Z-Score 標準化以顯著提升極弱訊號之特徵對比度。

- 輕量化二維卷積神經網路 (2D CNN): 設計輕量化雙層卷積結構，並於特徵提取末端引入自適應最大池化層 (Adaptive Max Pooling)，強制壓縮特徵圖以鎖定頻譜中的最高能量亮線，並透過高丟棄率 (Dropout=0.4) 防範過度擬合，滿足邊緣端即時推論之運算限制。
- 雙頻段距離衰減與地理高程驗證: 透過不同距離區間之推論測試，客觀對比雙頻段之環境穿透力與傳輸極限，並深入分析 500 公尺處因地理高程所形成之視距 (LoS) 優勢對訊號識別率的反常回升現象，藉此證實 AI 模型彌補傳統感官判讀盲點之可行性。

以下將針對通訊數據採集環境、數據前處理流程、CNN 網路架構設計，以及不同頻段與距離下之偵測效能評估進行逐一論述。

1. 通訊數據採集環境與設備配置

本計畫於植被密布的三汀山(如圖 22.)進行通訊數據採集，利用實體對講機與軟體定義無線電 (SDR) 模組(如圖 23.)，模擬真實山區的無線電傳播與衰減環境。採集作業在 50 至 500 公尺的直線距離內，針對特高頻 (VHF) 145.3 MHz 與超高頻 (UHF) 432.6 MHz 兩大頻段進行測試。實測結果顯示，145.3 MHz 頻段較易受地形與建築遮蔽導致訊號快速衰減，而 432.6 MHz 頻段在此植被覆蓋環境中，則展現出較佳的穿透力與遠距離傳輸表現。

2. 數據集建構與佈署規劃

為利於後續之模型訓練與特徵識別，原始蒐集之射頻數據均預先轉換為頻譜圖 (Spectrogram) 進行視覺化分析與特徵萃取。

(1) 訓練數據集 (Training Dataset) 之建構: 訓練集之佈署以訊號特徵之清晰度為篩選基準，確保模型能學習到明確的頻譜特徵，避免引入過多雜訊干擾收斂。

- 正樣本 (有訊號) (如圖 24.): 經人工檢視，僅保留頻譜圖中具備顯著特徵之數據。涵蓋範圍包含直線距離 50 至 200 公尺之雙頻段測試數據，以及 250 公尺處之 432.6 MHz 頻段數據。
- 負樣本 (無訊號 / 背景底噪) (如圖 25.): 於校園環境中獨立採集無發射訊號時的環境音與頻譜狀態，作為模型辨識之背景基準。

(2) 測試數據集 (Testing Dataset) 之建構: 測試集之佈署旨在

全面評估系統於不同距離與弱訊號條件下之偵測效能與泛化能力 (Generalization)。

- 正樣本 (有訊號): 完整納入直線距離 50 至 500 公尺區間之量測數據, 以嚴格檢驗系統在極限傳輸距離下的辨識率。
- 負樣本 (無訊號 / 背景底噪): 同樣採用校園環境中採集之無訊號數據進行對照與誤判率 (False Positive) 測試。

3. 數據前處理與特徵工程

為使模型能有效學習無線電訊號之時頻特徵, 原始採集之同相與正交 (I/Q) 訊號需經過一系列正規化之數位訊號處理 (DSP) 與特徵工程。

(1) 訊號降採樣與重組 (Downsampling & Reconstruction)

- 原始設備擷取之訊號採樣率為 256 kHz, 為濾除冗餘高頻雜訊並優化後續運算效率, 系統採用抽取法 (Decimation) 進行 8 倍降採樣, 將目標採樣率轉換為 32 kHz。
- 降採樣後之 I 與 Q 通道數據重新組合成複數基頻訊號 ($I + jQ$), 以保留完整之相位與振幅資訊。

(2) 訊號切片與時頻轉換 (Slicing & STFT)

- 序列訊號以 1024 個取樣點為固定長度進行時間切片 (Slicing)。針對長度不足之訊號段, 採用常數補零 (Zero-padding) 機制以維持維度一致性。
- 運用短時距傅立葉變換 (Short-Time Fourier Transform, STFT), 設定快速傅立葉變換點數 (NFFT) 為 256, 將一維時間序列轉換為二維頻譜圖 (Spectrogram)。並透過對數轉換, 將頻譜能量映射至分貝 (dB) 尺度 ($10 \log_{10}(|Z_{xx}|^2)$)。

(3) Z-Score 標準化 (Z-Score Normalization)

- 為克服山區環境底噪變異過大的問題, 特於頻譜生成後導入 Z-Score 標準化處理。將每張頻譜圖之分貝值調整為均值為 0、標準差為 1 之分佈。此一關鍵步驟能有效提升微弱訊號在頻譜圖上的特徵對比度, 使模型更容易鎖定並捕捉訊號的頻譜亮線。

4. AI 模型架構與訓練策略

本計畫設計並訓練專屬之二維卷積神經網路 (2D CNN), 以進行頻譜特徵之分類與辨識。資料集依循分層抽樣 (Stratified Sampling) 原則, 劃分為 80% 訓練集與 20% 驗證集, 確保各類別樣本比例均勻。

(1) 網路架構設計

- 特徵擷取層: 模型採用輕量化之雙層卷積架構。每層皆包含 3×3 卷積核 (Convolutional Layer)、批次正規化 (Batch Normalization) 以加速收斂, 並搭配 ReLU 激勵函數與 2×2 最大池化層 (Max Pooling)。

- 峰值能量聚焦：於特徵提取末端引入自適應最大池化層（Adaptive Max Pooling），將特徵圖強制壓縮為 4×4 網格。此設計旨在剔除無效的背景底噪，精確鎖定並保留頻譜中的「最高能量」特徵。
- 分類層：採用全連接層（Fully Connected Layer）進行最終分類，並於神經元間加入 40% 的丟棄率（Dropout = 0.4），以降低模型對特定特徵之依賴，避免過度擬合。

(2) 模型訓練參數與優化策略

- 超參數設定：訓練週期（Epochs）設定為 500，批次大小（Batch Size）為 1024。
- 優化器與損失函數：採用 AdamW 優化器（Learning Rate = 5×10^{-4} ），並配合權重衰減（Weight Decay = 1×10^{-4} ）作為額外的正規化手段；損失函數採用交叉熵損失（Cross-Entropy Loss）。

(三) SDR 緊急通訊救援系統(手機訊號辨識)

1. 研究目的與資料來源

本研究是針對遠傳 700 MHz LTE 上行頻段中的 713-723 MHz 範圍進行手機上行訊號偵測，目的是使用 RTL-SDR 被動式接收原始 IQ 資料，再透過頻譜能量變化或是特徵差異做模型推論，判斷目前掃描到的窄頻 channel 是否具有訊號證據。收集端由 RTL-SDR、天線與筆電組成(如圖 26.)，RTL-SDR 負責接收 700 MHz 附近射頻訊號並轉為 IQ 資料，筆電負責控制中心頻率、儲存 .npz 檔，每一筆.npz 檔裡都有原始 IQ samples，好去執行後續分析與作業。

(1) 資料收集設定

資料主要包含 background 與 active 兩種狀態。background 代表沒有明顯手機上行訊號的環境背景，例如手機飛航、關機或拿遠；active 代表遠傳手機靠近 SDR 並進行測速、上傳、傳檔或雲端同步。每筆資料都會寫入 metadata.csv，方便後續依狀態、距離、中心頻率與檔案位置追蹤。

本研究以 713 - 723 MHz 作為主要收集範圍。如(表 4)，掃描 714、716、718 MHz 作為中心頻率。原始取樣率設定為 2.4 MHz，每筆資料收集 0.2 秒，因此每筆約包含 480,000 個 complex IQ samples，並以 complex64 .npz 格式保存。資料狀態分為 background 與 active，其中 background 用來建立背景 baseline，active 則用來觀察手機上傳時是否產生可見上行訊號。每筆資料皆透過 metadata.csv 記錄狀態、距離、頻率與檔案位置，方便後續特徵抽取與模型訓練。




圖 26. 收集設備架構 RTL-SDR 連接電腦

表 4. 收集項目與參數設定

項目	設定	用途
收集頻段	713-723 MHz 中段	鎖定遠傳 700 MHz LTE 上行觀察範圍
使用頻率	714、716、718 MHz	排除 720、722 MHz 固定假峰影響
原始取樣率	2.4 MHz	保留原始 RTL-SDR IQ 頻寬
每筆時間	0.2 秒	每筆約 480,000 complex samples
儲存格式	complex64 .npy	減少容量並保留 FFT 分析所需之 IQ 資訊
資料狀態	background、active	background 建 baseline active 觀察可見訊號




圖 27. 管理館地下室 B1




圖 28. 工程館地下室 B1

(2) 訓練集與測試集：

為了使環境讓手機發射晶片開著時容易產生上行上行頻段，為此，本研究選擇收集數據地點分別為校內管理館 B1 地下停車場(圖 27.)與工程館 B1 地下室(圖 28.)。人為干擾部分也會影響到背景數據收集，所以收集時間都以半夜無人為主。



圖 29. 整體處理流程圖

表 5.前處理事項

前處理項目	參數	說明
目標取樣率	32,000 Hz	模型訓練與驗證使用的資料格式
切片長度	SLICE_N = 4096	每段約 0.128 秒
步距	HOP_N = 4096	無重疊切片
中心頻率排除	CENTER_EXCLUDE_KHZ = 2.0	排除中心 DC spike 區域
channel 半寬	CHANNEL_HALF_WIDTH_MHZ = 0.015	每個 channel 只看中心附近 ± 15 kHz
channel 邊緣排除	CHANNEL_EDGE_EXCLUDE_KHZ = 0.5	避免邊界 bin 造成不穩定特徵

表 6.特徵樣式

特徵名稱	意義	用途
ch_peak_over_floor_db	最高能量點高於底噪的程度	判斷是否有明顯尖峰訊號
ch_p99_over_floor_db	第 99 百分位能量高於底噪的程度	避免只看單一最高峰造成誤判
ch_top10_mean_over_floor_db	前 10 個高能量點相對底噪的平均差距	判斷訊號是否具有穩定能量
ch_occ_6db_ratio	超過底噪 6 dB 的頻率比例	判斷訊號是否佔據一定範圍
ch_peak_offset_khz	最高峰距離 channel 中心的偏移量	用來檢查是否為固定 offset 假峰
delta_ch_*	目前特徵與 background baseline 的差異	判斷目前訊號是否比背景更突出
delta_q95_ch_*	目前特徵與背景 q95 的差異	用來降低背景高峰造成的誤判

訓練集收集地為管理館地下室(圖 27.)。訓練集包含 background 與 active 資料,其中 active 依 0m、5m、25m、50m 等距離收集,用來讓模型學習不同距離下手機上行訊號的能量與特徵變化,後續判斷是否具有訊號。

測試集收集地為管理館地下室(圖 27.)。測試集除了包含 background 與 active5m、25m、50m 外我們額外去工程館 b1(圖 28.)收集 active 50m、100m 數據。讓模型成形後可以用不同地區、不同距離的數據也可以去判別。

(3) 資料切分

本研究資料切分時，會先根據 metadata.csv 整理每筆資料的狀態、距離與中心頻率，並只保留 background 與 active 兩種狀態，以及 714、716、718 MHz 三個中心頻率。資料切分不是直接以地點區分，而是依照狀態與距離建立標籤，例如 background、active_5m、active_25m、active_50m 等，再將資料約 75% 作為訓練資料、25% 作為測試資料。訓練資料用於建立 background baseline、產生 rule label 與訓練模型；測試資料則不參與訓練，只用於評估模型最後的判斷效果。

2. 前處理與窄頻 channel 特徵

(1) 整體處理流程

本研究的完整流程是由原始 IQ 收集開始，經過 32 kHz 降採樣、4096 samples 切片、FFT、特徵抽取、baseline delta 計算、rule label 建立、DNN/TFLite 推論，最後再把 channel-level 結果聚合成 file-level 判斷(圖 29.)。這個流程代表模型不是直接吃原始 IQ 波形，而是學習整理後的 channel features。

(2) 前處理與窄頻 channel 特徵

原始 IQ 的取樣率為 2.4 MHz，資料量較大，因此先將原始資料降採樣至 32 kHz，以降低 FFT、特徵抽取與模型推論的運算負擔。降採樣採用 scipy.signal.resample_poly() 與 Kaiser window 進行抗混疊處理。以每筆 0.2 秒資料為例，原始資料約為 480,000 samples，降採樣後約為 6,400 samples，32 kHz 取樣率只能觀察中心頻率附近約 ± 16 kHz。

a. 切片、FFT 與 DC 排除

如(表 5)，每筆 32 kHz IQ 會切成 4096 samples 的 slice，步距 HOP_N 也為 4096，因此不重疊切片。每個 slice 會先減去平均值降低 DC 成分，再套用 Hann window 減少頻譜洩漏，最後透過 FFT 轉成 dB power。設定 IGNORE_DC_BINS = 4，並額外排除中心 ± 2 kHz，以降低 RTL-SDR 中心頻率硬體假峰影響。

b. channel features 與 background baseline

完成 FFT 後，程式會針對每一筆 IQ slice 的指定頻道計算 channel features(如表 6)。這些特徵不是直接判斷手機是否 active，而是用來描述該頻道附近的頻譜能量變化，例如最高峰值、能量分布、超過底噪的比例，以及與背景 baseline 的差異。

本研究將 background 資料作為背景基準，先計算每個中心頻率與 channel 的背景特徵統計值，再把目前資料與背景基準相比，產生 delta 特徵。若目前資料的能量明顯高於 background baseline，代表該頻道可能出現 visible_signal。若與背景接近，則較可能為

表 7.模型主要參數整理

項目	設定 / 數值	說明
模型類型	DNN / Dense Neural Network	使用全連接神經網路進行 visible_signal 二元判斷
模型架構	feature_count $\rightarrow$ 128 $\rightarrow$ 64 $\rightarrow$ 32 $\rightarrow$ 1	輸入特徵向量後，經三層 Dense layer，最後輸出一個分數
輸入大小	$1 \times \text{feature_count}$	feature_count 為模型實際使用的特徵數量
輸出大小	1×1	輸出 0 到 1 的 visible_signal 機率分數
Epochs	180	模型最多訓練 180 輪，並使用 EarlyStopping 避免過度訓練
Batch size	256	每次訓練使用 256 筆樣本更新模型權重
Learning rate	3e-4	Adam optimizer 的學習率設定
Optimizer	Adam	用於更新模型權重的最佳化方法
Loss function	Binary Crossentropy	用於 visible_signal / no_visible_signal 二元分類
Threshold 選擇	validation file-level sweep	訓練後用 validation 的 file-level 結果選 high_threshold
缺值處理	median 補值	使用訓練時保存的 missing_value_fill_median
Normalization	模型內部處理	手機端或測試端不需額外做 z-score 或 min-max scaling

no_visible_signal。

c. baseline 與 rule label 的建立

background baseline 只使用 train split 中的原始 background 資料建立，不使用 test 資料，也不使用模型預測結果。baseline 會依照 center_freq_mhz 與 channel_mhz 分組，計算背景資料中的 peak、p99、top10、occ6、occ10 等統計值，例如 median、q95、q99。建立 baseline 後，程式會將目前資料的 channel features 與 background baseline 相減，得到 delta 特徵。

rule label 的目的，是先替每個 channel row 建立 visible_signal 或 no_visible_signal 標籤。V5F 不是直接把 active 全部當成 1，也不是直接把 background 全部當成 0，而是會檢查該 channel 是否有被觀測到、baseline 是否足夠，以及目前特徵是否同時滿足絕對能量門檻與 delta 差異門檻。若 active 資料與 background baseline 很接近，仍會被標為

no_visible_signal，代表當下沒有明顯可見訊號。

3. 模型設計與輸入輸出

如(表 7)，本研究使用的模型為 DNN，也就是 Dense Neural Network。模型的原始資料來源為 32 kHz IQ 資料與 metadata.csv，但模型本身不會直接輸入原始 IQ 波形，而是先將 IQ 資料經過切片、FFT、channel features 抽取，以及 background baseline delta 計算後，轉成一筆數值特徵向量再輸入模型。

模型輸入大小為 $1 \times \text{feature_count}$ ，其中 feature_count 代表模型實際使用的特徵數量。例如 peak、p99、top10、occupancy ratio、delta 特徵與 q95 delta 特徵等，都會依照固定順序排列成一行數字。這個順序不能任意改變，必須依照 model_feature_order.csv 或 channel_tflite_feature_info.json 裡面的 feature_order 輸入，否則模型會把欄位意義看錯，導致判斷結果不可靠。

模型架構為 $\text{feature_count} \rightarrow 128 \rightarrow 64 \rightarrow 32 \rightarrow 1$ 。前面三層為 Dense layer，用來學習各項頻譜特徵與 baseline 差異特徵之間的關係。最後一層為 sigmoid output，輸出一個 0 到 1 的分數。分數越接近 1，代表模型越認為該 channel 有 visible_signal、分數越接近 0，代表越接近 no_visible_signal。

模型訓練參數方面，epochs 設為 180，batch size 為 256，learning rate 為 $3e-4$ ，optimizer 使用 Adam，loss function 使用 Binary Crossentropy。模型內部包含 Normalization layer，因此在測試或手機端部署時，不需要另外做 z-score 或 min-max scaling，只要依照 feature_order 輸入正確特徵，並將缺失值用訓練時保存的 median 補值即可。

模型輸出大小為 1×1 ，也就是單一 visible_signal 機率分數。判斷時，若模型分數大於或等於 high_threshold / channel_threshold，就判定為 visible_signal。若低於門檻，則判定為 no_visible_signal。程式的 high_threshold 不是固定 0.5，而是在模型訓練完成後，使用 validation set 的 file-level threshold sweep 選出，用來兼顧 visible_signal 偵測率與背景誤判率。

另外，也會輸出 weak_threshold。當 score 介於 weak_threshold 與 high_threshold 之間時，表示該筆資料可能是 weak_visible_candidate，適合在手機端或即時端搭配連續 cycle 確認；但離線測試結果預設仍以 high_threshold 作為主要判斷標準，避免弱訊號候選直接放大 false positive。

(四) 行動端應用程式 (APP)

本應用程式基於 Android Studio 原生開發架構，作為整個「結合 IMU 與 AI 疲勞監測之登山安全輔助系統」的數據整合終端與

用戶互動介面。系統底層大量採用 Android 官方核心函式庫與多元第三方開源套件，以確保在資源受限之行動端環境下，仍具備高響應性、低功耗以及跨執行緒處理之高穩定性。

本研究開發之行動應用程式基於 Android Studio 原生架構，定位為整體登山安全輔助系統之**數據整合終端 (Data Aggregation Hub)**與**用戶互動介面 (User-System Interface)**。

為因應高山環境之資源受限性（如低運算算力、無網路覆蓋及有限電力），系統底層整合 Android 官方核心函式庫與多元第三方開源組件，以確保具備高響應性、低功耗及跨執行緒處理之高穩定性。本系統設計採「災前主動預警」與「災後應急搜救」之雙軌防線，將藍牙資料串流、邊緣 AI 推理、離線圖資定位、氣象資料快取及軟體定義無線電（SDR）訊號處理等異質功能進行模組化整合。

1. 系統核心底層架構

本應用程式之底層核心與介面設計主要由三個關鍵組件構成：

(1) AndroidX 核心函式庫 (androidx.*)

採用 AppCompatActivity、ConstraintLayout 與 CardView 等現代化組件，建構具備響應式設計 (Responsive Design) 的原生使用者介面，確保系統在不同螢幕尺寸與解析度之行動裝置上皆具備視覺一致性。

(2) Material Design 元件 (com.google.android.material)

導入 FloatingActionButton 等符合 Google Material Design 規範之視覺元件，優化人機互動邏輯與動態視覺反饋。

(3) 本地廣播管理器 (LocalBroadcastManager)

用於前端核心 Activity 與背景監測服務 (Background Service) 之間的通訊。藉由執行緒安全的非同步廣播機制，達成高效率的資料傳輸並降低系統開銷。

2. 核心功能模組技術剖析

系統依據功能屬性與運算邏輯，深度解耦為五大核心功能模組。各模組之軟體架構、算法實現與外部資料交互說明如下：

(1) 首頁狀態監控模組 (MainActivity)

本模組為應用程式之入口與系統狀態監控中心，負責統合多源硬體數據與背景服務狀態，其介面如圖 30 所示。

- a. **視覺與動畫引擎**：系統引入 Webkit 引擎 (android.webkit.WebView) 作為動態背景之渲染載體，讀取本地端靜態資源 (file:///android_asset/index.html)，以 HTML5/CSS3/JavaScript 技術實現高客製化之動態視覺。為避免原生 UI 衝突，系統關閉 WebView 之滾動機制與觸控攔截。此外，利用原生屬性動畫 (android.view.animation) 配合 OvershootInterpolator，實現頁面切換、底部導覽列滑動指示器及疲勞度量表之指針回彈特效。
- b. **硬體通訊介面**：直接呼叫 Android 原生藍牙 API (android.bluetooth.*)，透過 RFCOMM 協定與外部實



圖 30.首頁：疲勞監測




圖 31. 離線地圖



圖 32.天氣預報介面



圖 33.SDR 緊急求救系統

- d. 體登山杖感測器(如 ESP32)建立序列通訊 (Serial Port Profile, SPP)，實時接收慣性測量單元 (IMU) 之原始數據。

(2) 背景監測服務與邊緣 AI 推理模組 (Service & Classifier)

本模組於背景服務 (Background Service) 中常駐執行，主導藍牙進件數據處理、邊緣端疲勞辨識與個人化特徵校正。

a. 演算法與數學運算：

- 特徵對齊：整合 Apache Commons Math 套件 (org.apache.commons.math3.linear.*)，利用其矩陣運算 (RealMatrix)、向量運算 (RealVector) 與特徵值分解 (EigenDecomposition) 功能，實作相關性對齊 (Correlation Alignment, CORAL) 演算法，針對使用者步伐特徵進行 Z-Score 動態動態校正。

- **疲勞推論：**導入 TensorFlow Lite 行動端機器學習框架 (org.tensorflow.lite.Interpreter)，於邊緣裝置實時運行雙層卷積/循環神經網路，包含門控循環單元 (Gated Recurrent Unit, GRU) 模型與全連接 (Fully Connected, FC) 模型。

- b. **資料交互與持久化：**透過 org.json.* 處理器解析校正參數，並讀取 assets 目錄下之模型檔案 (gru_model.tflite、fc_model.tflite) 與統計特徵參數檔 (edge_stats.json)，以獲取全球通用之常態分佈平均值 (Global μ) 與標準差 (Global σ) 作為資料正規化基準。同時，利用 android.location.* 呼叫 LocationManager 獲取 GPS 經緯度，並依時間序列匯出為 JSON 格式之軌跡紀錄。

(3) 離線地理資訊與軌跡導覽模組 (MapActivity)

本模組專注於無網路山區環境之地理資訊渲染與歷史軌跡疊加，其實現介面如圖 31 所示。

- a. **地圖渲染引擎：**為擺脫對雲端地圖 API (如 Google Maps API) 之依賴，全面導入開源 osmdroid 引擎 (org.osmdroid.*)，負責本地圖磚渲染、多點觸控縮放處理、標記點 (Marker) 佈設及軌跡路線 (Polyline) 之繪製。並整合 CompassOverlay 與 ScaleBarOverlay 以提供方位角與比例尺等野外導覽資訊。
- b. **離線圖資與資料源：**透過 OfflineTileProvider 讀取打包於應用程式內部的實體 SQLite 圖磚資料庫 (TaiwanEMap.mbtiles，涵蓋臺灣全貌之經緯度圖磚)。地圖上之視覺化路線，則是由讀取由背景監測服務所產生的本地端軌跡資料 (Track_*.json) 並進行座標轉換而來。

(4) 即時氣象檢索與動態粒子渲染模組 (WeatherActivity)

本模組負責提供指定山區之即時天氣觀測與短期預報，並提供天氣視覺化反饋，其實現介面如圖 32 所示。

- a. **網路通訊與序列化：**採用 Retrofit2 型別安全 HTTP 客戶端進行非同步網路請求 (RESTful API)，並結合 Gson 轉換器工廠 (GsonConverterFactory)，將獲取之複雜 JSON 結構自動反序列化為 Java 對象 (JsonObject / JsonArray)。
- b. **地理定位與動態渲染：**整合 Google Play 服務定位 API (com.google.android.gms.location.*) 之 FusedLocationProviderClient，綜合 GPS、Wi-Fi 與基站訊號，以低功耗模式取得地理位置以自動配對行政區。此外，利用 Android Canvas 自定義繪圖組件，透過隨機數學函數實時運算並渲染下雨、雲朵飄動及陽光旋轉等天氣粒子特效 (WeatherBackgroundView)。
- c. **離線快取機制：**系統介接交通部中央氣象署 (CWA) 氣象資料開放平臺。為因應山區通訊斷網，設計了本地

序列化快取機制，將成功請求之氣象數據儲存於 weather_cache 目錄。若系統偵測到網路中斷，則自動加載歷史快取資料。

(5) 軟體定義無線電 (SDR) 應急搜救模組 (RadioActivity)

本模組為針對弱訊號與搜救情境設計之專業級電波監測與分析單元，介面如圖 33 所示。

- a. **訊號處理與時頻轉換**：系統建立本地端 TCP Socket 連線(java.net.Socket)，透過指定通訊埠(127.0.0.1:14423)串流接收來自外部獨立 SDR 驅動程式 App (marto.rtl_tcp_andro)所傳輸之百萬赫茲級 (MHz) I/Q 原始數位電波數據 (涵蓋 VHF/UHF 與 700MHz 等救難波段)。隨後，利用高效率 Java 快速傅立葉轉換函式庫 JTransforms (org.jtransforms.fft.FloatFFT_1D)，將原始時域訊號轉換為頻域 (Spectrum) 與時頻譜圖 (Spectrogram)。
- b. **邊緣端電波辨識**：二次部署 TensorFlow Lite 推理引擎，載入預訓練之二維卷積神經網路 (2D-CNN) 模型 (best_2d_cnn_32k_zscore-1_float32.tflite 與 channel_model_float32.tflite)，針對時頻譜圖進行特徵提取與弱訊號分類，實現搜救訊號之自動偵測與盲識別。

四、 軟硬體分析

(一) 軟體

- JupyterLab(如圖 34.)：基於網頁的互動式開發環境 (IDE)，具高度模組化架構。專案中用於感測器數據預處理、時間序列特徵工程，以及深度學習模型的原型設計與即時視覺化。
- PyTorch：開源的深度學習框架，具備動態計算圖與高效的 GPU 加速運算能力。本專案核心用於建構、訓練及優化「步態疲勞偵測」與「無線電訊號分類」兩款獨立之神經網路模型。
- TensorFlow Lite (TFlite)：針對行動端與邊緣設備優化的輕量化推論框架。用於將 PyTorch 訓練完成之模型 (.pth)，經由開源神經網路交換格式 (ONNX) 進行跨平台轉換與量化，最終生成 .tflite 檔部署至行動終端進行低延遲的即時推論。
- Android Studio(如圖 35.)：基於 IntelliJ IDEA 的官方 Android 整合開發環境。負責開發核心應用程式 (APP)，整合藍牙 (BLE) 與無線電接收端數據，並嵌入兩款 TFlite 模型進行終端運算與使用者介面呈現。

(二) 硬體

- Simond 500 Antishock 登山杖：作為智慧登山杖的機構主體，其具備的避震系統可緩衝行進間的衝擊，並作為內部電子元件與感測器的實體載體。
- BNO086 慣性測量單元：高精度的九軸運動感測器。內建感測器融合演算法，負責即時採集登山杖的加速度、角速度與磁力計數



圖 34. JupyterLab




圖 35. Android Studio



圖 36. Anytalk FT-388GPS



圖 37. 手機

據，用以分析使用者的步態特徵。

- **ESP32 微控制器**：具備無線通訊功能的低功耗微處理晶片。負責智慧登山杖感測端數據的即時採集、初步數位訊號處理，並透過內建的低功耗藍牙（BLE）將數據即時傳輸至行動運算終端。
- **3.7V 3000mAh 鋰電池**：專案感測端的電源供應系統。經實測其電容量可維持微控制器與感測器連續運作至少 8 小時以上，滿足戶外長時間登山健行之續航需求。
- **Anytalk FT-388GPS 無線電對講機**(如圖 36.)：系統無線電架構中的發射端設備。具備 GPS 定位功能，負責在山區或特定環境下進行射頻訊號的調變與發射。
- **軟體定義無線電 (SDR) 接收器**(如圖 23.)：系統無線電架構中的接收端硬體。負責接收發射端傳輸的射頻訊號，並將數據導入運算終端以進行解調與無線電模型的即時分析。
- **模型訓練與開發工作站 (PC)**：專案的核心運算與模型訓練平台。配備 13th Gen Intel Core i7-13700 CPU、64GB RAM 以及 NVIDIA GeForce RTX 4060 Ti GPU，負責處理大量時間序列數據、執行 PyTorch 模型的並行訓練，以及執行 ONNX 與 TFlite 的模型轉換流程。
- **邊緣運算驗證終端 (ASUS_X01AD, 如圖 37 左)**：2019 年發行的行動裝置。在相容性測試中，證實「步態疲勞偵測」與「無線電訊號分類」兩款 TFlite 模型皆能在此中低階硬體平台上順暢執行推論，惟受限於硬體世代，其使用者介面 (UI) 渲染伴隨輕微延遲。此裝置主要用於驗證本專案模型於舊款邊緣設備上的普及性與低運算成本。

- 邊緣運算展示終端 (ASUS ROG Phone 9 如圖 37 右)：2025 年發行的高效能行動裝置。具備頂級中央處理器與圖形加速晶片，專案中作為核心的應用程式展示平台。能同時兼顧兩款 TFlite 模型的高速即時推論，並維持使用者介面流暢的互動反饋。

五、測試結果

(一) 疲勞預警系統

1. 基準模型性能與交叉驗證表現 (測試集：源領域受測者)

本研究首先評估基礎模型（無自適應校正）在獨立測試集上的分類性能。實證結果顯示，模型在基準狀態下已具備高度準確之識別能力。為排除數據集不平衡（Class Imbalance）對模型評估帶來的偏誤，本研究採用 K 折交叉驗證（K-Fold Cross Validation）進行完整評估，各折（Fold）之各項核心評估指標如表 8. 所示。

交叉驗證結果顯示，各折之 Accuracy 與 Macro F1-Score 表現高度一致且均維持在 96% 以上之極高水準，並未出現因少數類別識別失敗而導致 F1-Score 大幅下滑之現象，充分證實本研究蒐集之基準數據集無數據不平衡問題。

由模型訓練之損失曲線（如圖 38.所示）觀測，模型在訓練初期收斂迅速，訓練損失（Train Loss）持續穩定下降。然而，在迭代約 100 個 Epochs 後，驗證集損失（Val Loss）呈現顯著的回升與反彈趨勢，表明模型已開始出現明顯的過擬合（Overfitting）現象。

為確保模型於未知數據上的泛化能力與客觀推論表現，本研究最終僅採用訓練 100 次（Epoch = 100）之最佳模型參數（即 best_gru.pth）作為後續所有推論與評估之黃金基準權重。

2. 跨使用者自適應機制消融實驗 (測試集：A 同學 / 馬那邦山)

為驗證本研究提出之「特徵空間對齊」與「動態決策閾值」雙層級校準機制之實質貢獻，本研究以 A 同學於馬那邦山採集之跨使用者數據進行消融實驗（Ablation Study）。詳細效能指標與對應之混淆矩陣(如圖 39.)(表 9.)分析如下：

- (1) Base Predictions：受限於個體物理條件與握持習慣變異，未校準前出現嚴重的領域偏移（Domain Shift）。其正常步態（notTired）正確識別僅 17 筆，高達 42 筆被錯判為疲勞狀態（Tired）。
- (2) Base Adapted Predictions ($T_h = 0.20$)：僅導入決策邊界修正。在未改變特徵幾何的情況下，透過保底門檻限制少數類別
- (3) 的觸發邊界，使 notTired 正確識別數提升至 31 筆（錯判降至 28 筆）。
- (4) CORAL Only Predictions：僅導入無監督流形消偏。透過線性轉換將新使用者特徵強力對齊至源領域分佈，在標準 Argmax 決策下，notTired 正確識別數大幅躍升至 44 筆（錯判降至 15 筆），證實空間對齊能有效消除特徵分佈的

表 8. 基準模型 K 折交叉驗證效能指標統計表

fold	acc	精準	recall	f1	mAP
fold1	97.82%	97.49%	96.52%	96.96%	98.38%
fold2	97.75%	97.13%	96.68%	96.90%	99.03%
fold3	97.56%	96.90%	96.33%	96.61%	98.71%
fold4	97.42%	96.92%	96.18%	96.52%	99.07%
fold5	97.62%	96.92%	96.79%	96.84%	99.07%




圖 38. 模型訓練之損失曲線




圖 39. A 同學自適應機制消融實驗

表 9. A 同學自適應機制消融實驗效能對比表

測試情境	準確率	Macro F1-Score
未校準之原始預測	67.2%	58.4%
僅動態閾值信心校正	76.2%	69.1%
僅 CORAL 特徵空間對齊	87.7%	81.3%
雙層級完全校準	93.4%	89.5%




圖 40. A、B 同學校正前後比較




圖 41. A 同學 LDA 結果圖
物理偏差。




圖 42. B 同學 LDA 結果圖

- (5) Adapted Predictions ($T_h = 0.20$)：整合特徵對齊與動態閾值之完全校準。系統效能達到最佳化 (Accuracy 達 93.4%)，使 notTired 正確識別數達到最高的 53 筆，錯判數降至極低的 6 筆，完整實現了隨插即用 (Plug-and-Play) 的高精準度偵測服務。

3. 跨使用者多場景實證與性能分歧分析 (測試集：A 同學 vs B 同學)

為進一步驗證系統於不同真實山域環境下的泛化邊界，本

研究引入 B 同學於橫嶺山採集之異源數據進行對比試驗。兩位受測者於校正前後之混淆矩陣對比參見圖 40。

- (1) **校正前表現：**A 同學與 B 同學均受到領域偏移影響，導致正常步態(notTired)出現顯著誤報。B 同學在基礎狀態下，有 130 筆 notTired 樣本被錯判為 Tired，10 筆被錯判為 Other。
- (2) **校正後表現：**導入雙層級完全校準機制後，A 同學之誤報率獲得大幅度收斂，分類趨於精準。然而，B 同學經校正後，notTired 正確識別數雖由 201 筆提升至 252 筆，但其誤判為 Tired 的筆數(77 筆)與誤判為 Other 的筆數(12 筆)依舊顯著高於基準預期，顯示該場景下仍存在嚴重的誤報現象。

經實地考察，此效能分歧根源於測試場域之物理限制。A 同學採集數據之馬那邦山沿途多為標準步道；而 B 同學採集數據之橫嶺山部分路段地形極為陡峭(坡度 $> 45^\circ$)，且包含大量需徒手拉繩攀登之非標準特殊地形。在此極端場景下，受測者無法正常使用登山杖，且難以維持標準的觸地步態，導致感測器所擷取之時序訊號特徵與源領域(正常步行)產生嚴重的非線性突變。

4. 特徵空間線性判別分析 (LDA 降維與域自適應論證)

為從幾何統計層面嚴謹驗證關聯對齊(CORAL)算法在不同受試者間的網域轉移效果，本研究對對齊後的特徵空間進行線性判別分析(LDA)降維投影。

在 A 同學(如圖 41.)的特徵分佈觀測中，經過 CORAL 對齊後，代表疲勞狀態的紅點(Tired)集中分布於流形下方，而代表正常狀態的綠點(notTired)則聚集於上方。兩者在投影空間中呈現出清晰且拉開的類別邊界，證實模型在此特徵表徵下具備極佳的線性可分性，因而能取得較好的分類決策效果。

反觀 B 同學(如圖 42.)經 CORAL 對齊後的特徵分佈，其空間幾何結構產生明顯畸變。由圖可知，大量的紅點與綠點在流形中央劇烈交織、糾纏在一起，無法形成如同 A 同學般清晰的獨立群聚。

此 LDA 空間分佈實證了極端地形所誘發的失穩訊號與非標準步態，在數學本質上已嚴重破壞了特徵的類別可分性，導致跨網域對齊算法(CORAL)在此特殊樣本上失效，進而確立了本系統在邊緣端自適應架構下的實用物理邊界。

(二) SDR 緊急通訊救援系統(對講機音訊辨識模型)

本研究透過實地採集之訊號進行二維卷積神經網路(2D CNN)的訓練與測試，並針對不同通訊頻段(145.3 MHz 與 432.6 MHz)在植被密布之山區環境下的傳輸極限與辨識效能進行分析。(如圖 43.)

1. 模型訓練收斂表現



圖 43. 接收端植物分佈




圖 44. 訓練之損失與準確率曲線圖

表 10. 各距離推論結果

距離	50m~200m	250m	300m	350m	400m	450m	500m
145.3	100%	3.22%	0.51%	0.63%	0.59%	0.50%	20.39%
432.6	100%	100%	83.23%	8.68%	14.12%	16.62%	96.06%

由訓練過程之損失函數與準確率曲線（Training & Validation Loss / Accuracy）觀察可知(如圖 44.)，本系統導入之 Z-Score 頻譜標準化前處理與 CNN 模型架構具備優異的特徵學習能力。模型於訓練初期即迅速收斂，歷經 500 個訓練週期（Epochs）後，驗證準確率（Validation Accuracy）穩定維持於 99% 以上，且訓練與驗證損失皆平穩貼近於零，無明顯過擬合（Overfitting）現象，為後續的距離極限測試奠定良好基礎。

2. 人耳與視覺之辨識基準測試

為確立 AI 模型之效益，本研究先以人為感官作為對照基準。將 SDR 模組採集之數據還原為音訊後，經實測，人耳僅能勉強聆聽並辨識直線距離 200 公尺以內之語音訊息。此外，若將原始數據轉換為頻譜圖，在超出有效通訊距離後，由於強烈的環境底噪干擾，肉眼亦無法從頻譜圖中觀察出任何具備顯著特徵的訊號亮線，傳統的視覺判讀在此環境下完全失效。

3. 雙頻段距離衰減與模型偵測效能

依據模型對測試集進行推論之結果(如表 10.)，可將訊號傳輸與 AI 辨識效能劃分為三個特性區間：

- (1) **近距離穩定傳輸區 (50m ~ 200m)**：在此距離區間內，145.3 MHz 與 432.6 MHz 兩頻段之模型辨識率皆達到 100%。AI 模型能完美克服該距離下的雜訊，準確還原並辨識語音特徵，表現與人耳極限持平甚至更為穩定。
- (2) **中遠距離訊號衰落區 (250m ~ 450m)**：隨著距離增加與植被遮蔽加劇，兩頻段展現出截然不同的物理穿透特性：
 - a. **145.3 MHz (VHF)**：訊號衰退極快，在 250 公尺處辨識率已驟降至 3.22%，300 公尺至 450 公尺區間更是幾乎無法偵測（辨識率低於 1%）。
 - b. **432.6 MHz (UHF)**：展現出優異的環境適應性與穿透力。在 250 公尺處仍保持 100% 的完美辨識率，最遠有效偵測距離可達 300 公尺（辨識率 83.23%）。直至 350 公尺處，訊號才發生顯著衰落（辨識率降至 8.68%），證明在該山區環境中，432.6 MHz 頻段更適合進行中長距離的訊號傳輸與 AI 偵測。
- (3) **地形與高程優勢區 (500m)**：實驗數據顯示，在最遠的 500 公尺測量點，兩頻段的辨識率皆出現反常的回升現象（145.3 MHz 回升至 20.39%，432.6 MHz 大幅回升至 96.06%）。經考查實際採集環境之地理條件，此現象肇因於 500 公尺處之測站海拔較高，具備地形上的視距（Line of Sight, LoS）優勢，且周圍植被遮蔽物大幅減少，使得無線電波能跨越低海拔的障礙物直接抵達接收端，進一步驗證了地形與高程對於山區無障礙通訊的決定性影響。

(三) SDR 緊急通訊救援系統(手機訊號辨識)

1. 模型結果

模型訓練曲線(圖 45.)，用來看模型訓練過程是否穩定。左邊是 Loss 曲線，train loss 和 validation loss 都快速下降並趨於穩定，代表模型誤差有降低；右邊是 AUC 曲線，train AUC 和 validation AUC 都接近 1，代表模型可以有效區分 visible_signal 和 no_visible_signal，整體沒有明顯訓練失敗或發散的情況。

模型最後偵測能力總結圖(圖 46.)，用 file-level 測試結果來看模型表現。整體準確率為 98.15%，背景正確率為 98.29%，可見訊號偵測率為 95.63%，代表模型大多能正確判斷有無可見訊號。誤判部分中，False Positive Rate 為 1.71%，表示少部分背景被誤判成有訊號；False Negative Rate 為 4.37%，表示少部分有訊號資料被漏判。

2. 測試資料用模型結果

比較不同距離下，模型判斷 visible_signal 的最後準確率(如圖 47.)。結果顯示 5m、25m、50m、100m 的準確率都在 87% 以上。其中 25m 最高，為 93.8%、5m 較低，為 87.1%。

整體來看，模型在不同距離下仍能維持一定準確率，代表模型不只適用於單一距離。




圖 45. 模型訓練曲線




圖 46. 模型最後偵測能力總結圖




圖 47. 不同距離下 visible_signal 最後準確率

六、 結論

本專題成功研發一套「結合 IMU 與 AI 疲勞監測之登山安全輔助系統」，針對現行山域防護中「災前疲勞隱性成因難以監測」與「災後通訊盲區難以精確搜索」兩大實務痛點，提出了具備高泛化力、低侵入性且兼顧災前預警與災後救援的軟硬體閉環解決方案。

在災前防護維度上，本系統創新採用非侵入式設計，將六軸慣性感測器(IMU)整合於單一智慧登山杖中，成功排除手環等傳統穿戴裝置易受非目的性肢體動作干擾的缺點。面對高山步態公開資料集匱乏的限制，研究團隊實地採集逾 20 小時真實山域步態數據。在模型訓練的數據擴充策略上，團隊導入去噪擴散機率模型(DDPM)生成 1,000 筆 notTired 合成樣本並獨立作為分類器的訓練集補充，在不更動原始觀測數據庫的前提下，成功將基準狀態訓練規模擴充至 3,358 筆（包含增強數據）。邊緣端部署之輕量化三層門控循環單元（GRU）模型在同源數據下展現出 97.49% 的平均交叉驗證準確率；而針對個體行為與地形變異引發的領域偏移(Domain Shift)，透過整合 CORAL 領域自適應特徵空間對齊與動態決策閾值調整，成功將異源使用者的辨識準確率大幅提升至 93.4%。本研究亦透過主成分分析(PCA)降維投影，嚴謹論證了極端陡峭地形（如需拉繩之非標準步態）對線性對齊的幾何破壞性，從科學層面確立了邊緣自適應架構的物理實用邊界。

在災後應急通訊維度上，為克服高山區域缺乏行動網路且使用者依法不得任意發射無線電之實務與法規限制，本系統整合軟體定義無線電(SDR)技術與二維卷積神經網路(2DCNN)，建立「被動寬頻掃描、主動聲音示警」的逆向救援機制。系統常駐監聽並全面掃描 VHF (144–146 MHz) 與 UHF (430–440 MHz) 等官方搜救與業餘無線電全頻段。實地測試證實，在植被密布的複雜地貌中，當搜救隊伍於此頻段發射搜索訊號時，本系統能有效突破人耳聽覺與肉眼看頻譜的感官極限，並在最遠達 300 公尺內（以 432.6 MHz 為例）達到 83.23% 以上的辨識率；在具備高程視距(LoS)優勢的 500 公尺測點，更實現高達 96.06% 的弱訊號自動偵測率。一旦捕捉並識別出搜救方的廣播特徵，即可主動驅動手機終端發出高分貝警報聲，引導搜救人員鎖定隱蔽受難者，打破地形死角。同時，系統延伸至 700 MHz LTE 手機上行訊號偵測，利用卷積神經網路(DNN)學習特徵樣式與背景基準的差異(Delta 特徵)，在不同距離下維持 87% 以上的辨識精度，成功建立局部微觀的無線電盲識別機制。

最終，本研究將藍牙串流、TensorFlow Lite 邊緣推理引擎、基於 MBTiles 的離線圖資定位及中央氣象署(CWA)數據快取機制，深度解耦並模組化整合至 Android 原生行動應用程式中，確保系統在極端斷網環境下仍具備高響應性與全天候穩定運作能力。綜上所述，本專題不僅完全符合電信法規規範，更落實了由智慧感測登山杖到協同救援的閉環防線，在運算資源受限的邊緣端實現了隨插即用(Plug-and-Play)的個人化校準與弱訊號辨識，切實解決了登山者疲勞失穩及盲區搜救難以鎖定的技術痛點，為山域安全保障與移動應急通訊領域提供了極具實務落地價值的實證基礎與創新框架。

七、 建議

儘管本專題已成功建構一套具備實用價值之「結合 IMU 與 AI 疲勞監測之登山安全輔助系統」，但在系統的深度優化與未來實際落地應用上，仍有以下幾個面向值得進一步探討與修正：

(一)擴充真實步態資料庫與提升模型泛化能力

目前受限於硬體數量、體能極限與天候窗口，系統的真实步態數據主要由特定受試者於中低海拔步道採集。雖然本研究已導入擴散模型 (DDPM) 與 CORAL 自適應演算法來克服數據限制與領域偏移，但未來建議可擴大研究規模，納入更多不同體態、年齡、負重條件與攀登經驗的測試者進行實地驗證。透過大幅增加真實受試者的多樣性，能進一步確保 AI 模型在面對更廣泛人群時的泛化能力與穩健性。

(二)硬體功耗管理與系統續航力最佳化

考量高山攀登動輒數天之行程，邊緣設備 (ESP32) 與 SDR 模組的高頻取樣及運算將帶來顯著的電量消耗。建議未來可於系統中導入動態電源管理機制 (如：在地形平緩且步態極度穩定時自動降低 IMU 取樣率，或令 AI 推理模組進入深度休眠)，甚至於登山杖硬體中整合微型太陽能板或壓電材料 (Piezoelectric)，以回收行走時的動能，進一步延長系統在無電力補給環境下的運作時間。

(三)多模態生理數據之融合潛力

本專題在數據標記階段，已將智慧手環的心率數據作為實時人工標籤切換的客觀佐證，但為維持零穿戴負擔，最終成品並未將心率輸入 AI 模型。未來在商業化或進階應用中，可於手機 APP 端增設「進階雙效模式」，允許願意配戴智慧手錶的使用者將心率、血氧等生理指標透過藍牙與步態特徵進行「多模態數據融合 (Multimodal Sensor Fusion)」，以達到更為精準的醫療級疲勞預防效果。

(四)感測器物理姿態自適應校正機制

未來系統若進行硬體微型化與機構整合，感測晶片勢必嵌入至登山杖內部，屆時組裝公差、杖體形變或使用握持習慣之異質性，皆會改變慣性感測器 (IMU) 的初始幾何姿態。

為確保 AI 模型的特徵輸入不因物理偏角而失真，系統建議導入「動態坐標系旋轉對齊算法 [37]」。其核心邏輯係利用行進初期之靜態或規律步態時段，擷取重力加速度向量以鎖定垂直軸 (Z 軸)，並透過主成分分析 (PCA) 或四元數變換定義主前進方向，藉此建立動態旋轉矩陣，將異質偏角下的慣性訊號即時投影至標準虛擬運動坐標系，實現隨插即用之姿態自校正效果。

八、 參考文獻

- [1] R. De Decker, G. Tölken, and J. Roos, “Human factors: Predictors of avoidable wilderness accidents?” *African Journal of Emergency Medicine*, vol. 7, no. 4, pp. 152 – 155, 2017.
- [2] P. Parijat and T. E. Lockhart, “Effects of quadriceps fatigue on the biomechanics of gait and slip propensity,” *Gait & Posture*, vol. 28, no. 4, pp. 568–573, 2008.
- [3] H. Pawar, K. Ray, and K. Kishore, “Cognitive Challenges at High Altitude: Human Responses and Adaptation Strategies,” *Journal of Mountain Medicine and Physiology*, vol. 12, no. 1, pp. 15–29, 2025.
- [4] R. Heggie and J. Heggie, “Search and rescue trends associated with recreational travel in US national parks,” *Journal of Travel Medicine*, vol. 16, no. 1, pp. 23–27, 2009.

- [5] P. McIntosh, J. Swain, and D. Smart, "Risk factors in mountain recreation incidents," *Wilderness & Environmental Medicine*, vol. 22, no. 3, pp. 221–228, 2011.
- [6] X. Liu and J. Liu, "Research progress on exercise fatigue from the perspective of fatigue biomarkers," *PeerJ*, vol. 14, p. e20424, 2026.
- [7] R. M. Enoka and J. Duchateau, "Muscle fatigue: What, why and how it influences muscle function," *The Journal of Physiology*, vol. 586, no. 1, pp. 11–23, 2008.
- [8] G. Y. Millet, K. Tomazin, S. Verges, C. Vincent, R. Bonnefoy, R.-C. Boisson, et al., "Neuromuscular consequences of an extreme mountain ultra-marathon," *PLoS ONE*, vol. 6, no. 2, p. e17059, 2011.
- [9] J. J. Wan, Z. Qin, P. Y. Wang, Y. Sun, and X. Liu, "Muscle fatigue: General understanding and treatment," *Experimental & Molecular Medicine*, vol. 49, no. 10, p. e384, 2017.
- [10] M. A. Faghy and P. I. Brown, "Thoracic load carriage-induced respiratory muscle fatigue," *European Journal of Applied Physiology*, vol. 114, no. 5, pp. 1085–1093, 2014.
- [11] B. D. Johnson, E. A. Aaron, M. A. Babcock, and J. A. Dempsey, "Respiratory muscle fatigue during exercise: Implications for performance," *Medicine & Science in Sports & Exercise*, vol. 28, no. 9, pp. 1129–1137, 1996.
- [12] M. Helbostad, R. Leirfall, and T. Moe-Nilssen, "Physical fatigue affects gait characteristics in older adults," *The Journals of Gerontology Series A: Biological Sciences and Medical Sciences*, vol. 62, no. 9, pp. 1010–1015, 2007.
- [13] A. Nagano, A. Yoshioka, and S. Hay, "Effects of fatigue on walking stability and balance control," *Human Movement Science*, vol. 33, pp. 55–65, 2014.
- [14] F. A. Barbieri, R. Vitória, P. C. Simieli, J. M. Orcioli-Silva, and L. T. Gobbi, "Impact of muscular fatigue on gait variability and stability," *Gait & Posture*, vol. 45, pp. 85–90, 2016.
- [15] R. Beurskens, M. Haeger, R. Kliegl, K. Roecker, and U. Granacher, "Postural control in dual-task situations: Does whole-body fatigue matter?," *PLoS ONE*, vol. 11, no. 1, p. e0147392, 2016.
- [16] Y. Koshimizu, A. Fukuhara, Y. Yamamoto, and A. Kijima, "Adaptive gait transition in trekking pole-assisted hiking due to fatigue and staircase height elevation," *Frontiers in Sports and Active Living*, vol. 7, p. 1669574, 2026.
- [17] A. Mannini and A. M. Sabatini, "Machine learning methods for classifying human physical activity from on-body accelerometers," *Sensors*, vol. 10, no. 2, pp. 1154–1175, 2010.
- [18] A. Del Din, A. Godfrey, and L. Rochester, "Free-living gait characteristics in ageing and disease measured using wearable sensors," *Gait & Posture*, vol. 49, pp. 46–54, 2016.
- [19] J. Howcroft, E. D. Lemaire, J. Kofman, and W. E. McIlroy, "Wearable-sensor-based classification models of faller status in older adults," *PLoS ONE*, vol. 12, no. 4, p. e0175192, 2017.
- [20] P. Chang, C. Wang, Y. Chen, G. Wang, and A. Lu, "Identification of runner fatigue stages based on inertial sensors and deep learning," *Frontiers in Bioengineering and Biotechnology*, vol. 11, p. 1302911, 2023.
- [21] Y. Wang, R. Dang, B. Hu, and Q. Wang, "Deep learning-based fatigue monitoring in natural environments: Multi-level fatigue state classification," *Bioengineering*, vol. 12, no. 12, p. 1374, 2025.
- [22] C. Baccouch and C. Bahar, "Embedded system for ECG signal monitoring and fatigue detection in elderly individuals using machine learning models,"

International Journal of Advanced Computer Science and Applications, vol. 16, no. 9, 2025.

- [23] J. Kim, H. Kim, J. Lee, J. Lee, J. Yoon, and S.-K. Ko, "A deep learning approach for fatigue prediction in sports using GPS data and rate of perceived exertion," *IEEE Access*, vol. 10, pp. 103056–103064, 2022.
- [24] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [25] F. A. Gers, J. Schmidhuber, and F. Cummins, "Learning to forget: Continual prediction with LSTM," *Neural Computation*, vol. 12, no. 10, pp. 2451–2471, 2000.
- [26] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP)*, Doha, Qatar, 2014, pp. 1724–1734.
- [27] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, "Empirical evaluation of gated recurrent neural networks on sequence modeling," *arXiv:1412.3555*, 2014.
- [28] A. Srivastava, K. S. Sangwan, and Dhiraj, "Real-time driver drowsiness detection using GRU with CNN features," in *Computer Vision and Image Processing (CVIP 2020)*, Singapore: Springer, 2021, pp. 147 – 158.
- [29] S. Li et al., "A fatigue driving recognition method based on WOA-Attention-GRU," in *Proc. IEEE International Conference on Control, Electronics and Computer Technology (CECT)*, 2023.
- [30] T. Holcer, M. B. Vrhovec, and P. Pehani, "Communication technologies in emergency situations," *Electronics*, vol. 11, no. 7, p. 1155, 2022.
- [31] J. Mitola, "Software radios: Survey, critical evaluation and future directions," *IEEE Aerospace and Electronic Systems Magazine*, vol. 8, no. 4, pp. 25–36, 1993.
- [32] W. Tuttlebee, *Software Defined Radio: Enabling Technologies*. New York, NY, USA: Wiley, 2002.
- [33] H. I. Kobo, A. M. Abu-Mahfouz, and G. P. Hancke, "SDR-based reliable and resilient wireless network for disaster rescue operations," in *Proc. IEEE Global Humanitarian Technology Conference (GHTC)*, Seattle, WA, USA, 2019, pp. 1–7.
- [34] D. O’Keeffe and B. O’Flynn, "Autonomous unmanned aerial vehicle for search and rescue using software defined radio," in *Proc. IEEE 89th Vehicular Technology Conference (VTC2019-Spring)*, Kuala Lumpur, Malaysia, 2019, pp. 1–5.
- [35] S. Hershey et al., "CNN architectures for large-scale audio classification," in *Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, New Orleans, LA, USA, 2017, pp. 131–135.
- [36] A. Saeed, L. Peltonen, H. R. Rossi, et al., "Federated learning for keyword spotting and audio classification on edge devices," in *Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2021, pp. 3175–3179.
- [37] P. G. Fontes, et al., "An IMU-to-Body Alignment Method Applied to Human Gait Analysis," *Sensors*, vol. 16, no. 12, p. 2090, 2016.